
Laboratorio 7

Spark MLlib

Perfiles laborales y predicción salarial con ENEIC

Repositorio oficial del proyecto

[github.com/DanielBarillasM/
Laboratorio-7_Spark_Grupo-1_DS_Sec-10](https://github.com/DanielBarillasM/Laboratorio-7_Spark_Grupo-1_DS_Sec-10)

Jorge Gabriel Palacios Sales

231385

Pablo Daniel Barillas Moreno

22193

Roberto Emiliano Otoniel

23968

Presentación del repositorio

Este repositorio documenta un flujo de análisis reproducible con Apache Spark para estudiar perfiles de trabajadores asalariados y validar modelos de predicción del salario mensual a partir de las bases de Personas de la Encuesta Nacional de Empleo e Ingresos Continua (ENEIC).

Python 3.11

PySpark 3.5.1

Spark MLlib

ENEIC 2025–2026

Contenido principal

Notebook ejecutado

Código, tablas, gráficos e interpretaciones de las actividades 1–8, ejecutado de principio a fin en Docker.

Módulos reproducibles

Carga y armonización, auditoría de calidad, EDA, KMeans, regresión lineal, Random Forest, análisis de errores e interpretación.

Informe técnico

Documento $\text{\LaTeX}$ compilado con metodología, resultados en 2026, análisis de errores, conclusiones y limitaciones.

Resultados

Tablas CSV y figuras PNG generadas sobre los conjuntos completos o agregados permitidos.

Alcance

- Actividades 1–4: carga y calidad, estadística descriptiva, correlaciones con MLlib y segmentación KMeans.
- Actividades 5–6: pipelines de regresión lineal y Random Forest con selección en 2025T4.
- Actividad 7: reentrenamiento con todo 2025 y evaluación única en 2026T1 sobre los mismos registros.
- Actividad 8: gráficos de predicción y residuos, errores por nivel educativo, dominio y percentil salarial, y discusión final.

Reproducibilidad

El proyecto fija semilla 42, usa exactamente seis predictores autorizados, mantiene los datos y modelos pesados fuera de Git y documenta su ubicación en el README. Las métricas se calculan con Spark sobre el conjunto completo; pandas se limita a agregados o muestras gráficas de hasta 5,000 registros.

Acceso directo

github.com/DanielBarillasM/
Laboratorio-7_Spark_Grupo-1_DS_Sec-10