

UNIVERSIDAD DEL VALLE DE GUATEMALA

Laboratorio 7

Spark MLlib

Perfiles laborales y predicción salarial con ENEIC

Avance funcional del 75% · Actividades 1–6 completas

Jorge Gabriel Palacios Sales

231385

Pablo Daniel Barillas Moreno

22193

Roberto Emiliano Otoniel

23968

CC3084 · Data Science · Sección 10 · Grupo 1

Segundo semestre 2026

1 Resumen ejecutivo

Se construyó un flujo reproducible con Python 3.11, Spark 3.5.1 y la API `pyspark.ml`. El avance procesa las bases oficiales de Personas ENEIC, preserva su procedencia, audita cada exclusión, caracteriza la población analítica, compara segmentaciones KMeans y valida dos familias de regresión mediante una separación temporal. Los resultados son no ponderados y no deben interpretarse como estimaciones oficiales ni relaciones causales.

1.1 Hallazgos principales

Después de aplicar los criterios de elegibilidad se conservaron **53,025** registros de 2025. El salario medio fue **Q3,421.68** y la mediana **Q3,000.00**; esta separación evidencia asimetría y la influencia de valores altos. La asociación lineal absoluta más alta con salario entre los predictores numéricos corresponde a **antigüedad** ($|r| = 0.180$). KMeans seleccionó **Perfil laboral (sin salario)** con $K = 2$ y silhouette 0.5545. En validación temporal, **RF_50_arboles_d7** obtuvo el menor RMSE (Q2,074.15), con MAE Q1,109.94 y $R^2 = 0.4831$. La prueba 2026 permanece reservada.

1.2 Retención por período

Período	Antes	Después	Excluidos	Retención
2025T1	51,588	13,419	38,169	26.01%
2025T2	51,167	13,492	37,675	26.37%
2025T3	51,583	13,450	38,133	26.07%
2025T4	49,338	12,664	36,674	25.67%

Table 1: Registros antes y después de los filtros comunes.

1.3 Descriptivos principales

Variable	Media	Mediana	DE	P25	P75	P95
salario_mensual	3,421.68	3,000.00	2,902.11	1,800.00	4,000.00	8,000.00
edad	35.19	33.00	13.52	24.00	44.00	61.00
antigüedad	5.56	2.00	7.83	0.50	7.00	21.42
horas_semanales	46.31	45.00	18.63	40.00	55.00	80.00

Table 2: Estadísticas calculadas sobre todos los registros elegibles de 2025.

1.4 Comparación de modelos en 2025T4

Modelo	MAE (Q)	RMSE (Q)	R^2
RF_50_arboles_d7	1,109.94	2,074.15	0.4831
LR_sin_regularizacion	1,210.14	2,186.42	0.4257
Referencia: media de entrenamiento	1,672.50	2,889.57	-0.0031

Table 3: Métricas no ponderadas sobre el mismo conjunto de validación.

2 Datos y preparación

Se utilizaron los cuatro trimestres de 2025 para desarrollo y el primer trimestre de 2026 como prueba reservada. Cada Excel se leyó individualmente con `openpyxl`; únicamente las variables necesarias se convirtieron a un DataFrame Spark con esquema explícito y luego a Parquet. La unión de 2025 se realizó con `unionByName`, indispensable porque 2025T4 contiene 302 columnas originales y los otros cortes 270.

La población analítica exige edad mayor o igual a 15, condición de ocupado, categoría asalariada, salario mensual positivo y finito, antigüedad coherente y una jornada entre 1 y 168 horas. Los faltantes o códigos categóricos no reconocidos se identifican como `DESCONOCIDO`; el nivel educativo 0 se conserva como *Ninguno*. No se imputó, recortó ni transformó el salario objetivo.




Figure 1: Composición de los registros elegibles de 2025.

3 Exploración y relaciones




Figure 2: Distribución salarial. La escala logarítmica se usa solo para visualización.




Figure 3: Salario mediano por nivel educativo y categoría ocupacional.




Figure 4: Correlaciones de Pearson calculadas con todos los registros elegibles de 2025.

4 Segmentación KMeans

Se estandarizaron las variables y se compararon $K = 2, 3, 4, 5$ tanto con un perfil laboral sin salario como con un perfil económico que lo incorpora. La elección se basa en silhouette; la descripción de los clústeres es relativa a las medias del conjunto y no representa categorías naturales.




Figure 5: Selección de K y sensibilidad a la inclusión del salario.

5 Modelado supervisado

Los modelos utilizan exactamente edad, antigüedad, horas semanales, nivel educativo, categoría ocupacional y dominio. Se entrenó con 2025T1–T3 y se validó en 2025T4. Los indexadores, codificadores y estimadores se ajustaron solo con entrenamiento. La regresión lineal compara tres regularizaciones y Random Forest dos configuraciones de árboles y profundidad.

6 Estado y trabajo restante

Las actividades 1–6 están ejecutadas y sus modelos ganadores se guardaron fuera de Git. Para la entrega final se reentrenará cada configuración seleccionada con todo 2025, se evaluará una sola vez sobre 2026T1 y se completarán gráficos de predicción, residuos, errores por educación y dominio, análisis por percentiles y discusión final.

7 Reproducibilidad y limitaciones

El notebook fija semilla 42, mantiene el test temporal aislado y limita cualquier transferencia a pandas a agregados o una muestra gráfica de 5,000 filas. FACTOR se conserva para documentar el diseño, pero las métricas obligatorias son no ponderadas. El repositorio no incluye Excel, Parquet ni modelos por su tamaño; el README documenta las rutas y dependencias.




Figure 6: RMSE de validación frente al modelo de referencia.

8 Fuente

Instituto Nacional de Estadística de Guatemala. *Encuesta Nacional de Empleo e Ingresos Continua (ENEIC)*, bases de Personas 2025–2026.

<https://www.ine.gob.gt/encuesta-nacional-de-empleo-e-ingresos/>

Kassis, T., Agarwal, V., He, Y., Patel, D. y Brueckner, A. M. (2026). *Scientific Agent Skills: A Library of Procedural Knowledge for Research Agents*. arXiv:2609.00065. DOI: 10.48550/arXiv.2609.00065.