

UNIVERSIDAD DEL VALLE DE GUATEMALA

Laboratorio 7

Spark MLlib

Perfiles laborales y predicción salarial con ENEIC

Entrega final · Actividades 1–8 completas

Jorge Gabriel Palacios Sales

231385

Pablo Daniel Barillas Moreno

22193

Roberto Emiliano Otoniel

23968

CC3084 · Data Science · Sección 10 · Grupo 1

Segundo semestre 2026

1 Resumen ejecutivo

Se desarrolló un flujo reproducible con Python 3.11, Spark 3.5.1 y `pyspark.ml`. El estudio armoniza las bases de Personas ENEIC, identifica perfiles mediante KMeans y compara regresión lineal con Random Forest para estimar el salario mensual. La selección se realizó con 2025T4; después, las configuraciones ganadoras se reentrenaron con todo 2025 y se evaluaron una sola vez en 2026T1.

1.1 Hallazgos principales

Después de aplicar los criterios de elegibilidad se conservaron **53,025** registros de 2025. El salario medio fue **Q3,421.68** y la mediana **Q3,000.00**; esta separación evidencia asimetría y la influencia de valores altos. La asociación lineal absoluta más alta con salario entre los predictores numéricos corresponde a **antigüedad** ($|r| = 0.180$). KMeans seleccionó **Perfil laboral (sin salario)** con $K = 2$ y silhouette 0.5545. En validación temporal (2025T4), **RF_50_arboles_d7** obtuvo el menor RMSE (Q2,074.15). En la prueba final (2026T1, 13,258 registros), **RF_50_arboles_d7** obtuvo el mejor desempeño: MAE Q1,141.51, RMSE Q2,050.55 y $R^2 = 0.4887$.

1.2 Retención por período

Período	Antes	Después	Excluidos	Retención
2025T1	51,588	13,419	38,169	26.01%
2025T2	51,167	13,492	37,675	26.37%
2025T3	51,583	13,450	38,133	26.07%
2025T4	49,338	12,664	36,674	25.67%

Table 1: Registros antes y después de los filtros comunes.

1.3 Descriptivos principales

Variable	Media	Mediana	DE	P25	P75	P95
salario_mensual	3,421.68	3,000.00	2,902.11	1,800.00	4,000.00	8,000.00
edad	35.19	33.00	13.52	24.00	44.00	61.00
antigüedad	5.56	2.00	7.83	0.50	7.00	21.33
horas_semanales	46.31	45.00	18.63	40.00	55.00	80.00

Table 2: Estadísticas calculadas sobre todos los registros elegibles de 2025.

1.4 Comparación de modelos en 2025T4

Modelo	MAE (Q)	RMSE (Q)	R^2
RF_50_arboles_d7	1,109.94	2,074.15	0.4831
LR_sin_regularizacion	1,210.14	2,186.42	0.4257
Referencia: media de entrenamiento	1,672.50	2,889.57	-0.0031

Table 3: Métricas no ponderadas sobre el mismo conjunto de validación.

2 Datos, trazabilidad y preparación

Cada Excel se procesó por separado con `openpyxl`; únicamente las variables requeridas se convirtieron a Spark con esquema explícito y se guardaron en Parquet. Se conservaron `TRIMESTRE`, `archivo_origen`, `periodo_archivo`, año y trimestre calendario. Los cuatro archivos de 2025 se combinaron con `unionByName`, porque 2025T4 contiene 302 columnas y los otros cortes 270.

La población analítica incluye personas de al menos 15 años, ocupadas, asalariadas según los códigos 1–4, con salario positivo y finito, antigüedad coherente y jornada habitual entre 1 y 168 horas. No se imputó, recortó ni transformó el salario objetivo. Los códigos ausentes o no reconocidos se trataron como `DESCONOCIDO`; educación 0 se mantuvo como *Ninguno*.

3 Exploración y relaciones




Figure 1: Composición de los registros elegibles de 2025.




Figure 2: Distribución salarial; la escala logarítmica se usa únicamente para visualizar.




Figure 3: Salario mediano por educación y categoría ocupacional.




Figure 4: Correlaciones de Pearson calculadas sobre todos los registros elegibles de 2025.

4 Segmentación y validación de modelos

KMeans comparó $K = 2, 3, 4, 5$ con variables estandarizadas, tanto con un perfil laboral sin salario como con un perfil económico que sí lo incorpora. Para el modelado supervisado se utilizaron exactamente edad, antigüedad, horas semanales, educación, categoría ocupacional y dominio.




Figure 5: Selección de K y sensibilidad a incluir el salario.

5 Evaluación final en 2026T1

Los pipelines completos se reajustaron con 2025T1–T4. Ambos modelos se evaluaron sobre las mismas claves elegibles de 2026T1, sin seleccionar de nuevo hiperparámetros.

Modelo	Configuración	Registros	MAE (Q)	RMSE (Q)	R^2
RF_50_arboles_d7	numTrees=50, maxDepth=7	13,258	1,141.51	2,050.55	0.4887
LR_sin_regularizacion	regParam=0.0, elasticNetParam=0.0	13,258	1,240.71	2,163.75	0.4307
Referencia: media 2025	media salarial 2025 completo	13,258	1,718.09	2,871.42	-0.0025

Table 4: Métricas en 2026T1, no ponderadas y calculadas sobre todo el conjunto de prueba.

Conjunto	Registros
Test elegible 2026T1	13,258
Predicciones LR_sin_regularizacion	13,258
Predicciones RF_50_arboles_d7	13,258
Registros compartidos (join por clave)	13,258
Claves distintas compartidas	13,258

Table 5: Ambos modelos se evalúan sobre exactamente los mismos registros (misma clave y mismo conteo).




Figure 6: Comparación de RMSE en validación temporal 2025T4.

Modelo	RMSE 2025T4	RMSE 2026T1	Cambio	Mejora vs. referencia
RF_50_arboles_d7	2,074.15	2,050.55	-23.60	28.59%
LR_sin_regularizacion	2,186.42	2,163.75	-22.67	24.65%
Referencia: media 2025	2,889.57	2,871.42	-18.15	0.00%

Table 6: Estabilidad temporal del RMSE y mejora frente a la referencia de la media de 2025.

En 2026T1, **RF_50_arboles_d7** obtuvo el menor error (MAE Q1,141.51, RMSE Q2,050.55, R^2 0.4887); el otro algoritmo, **LR_sin_regularizacion**, obtuvo MAE Q1,240.71, RMSE Q2,163.75 y R^2 0.4307. La referencia (media de 2025) tiene RMSE Q2,871.42 y R^2 -0.0025, y el ganador reduce ese RMSE en 28.59%. El ganador de validación coincide con el de prueba.

6 Visualización y análisis de errores

Se definió el residuo como salario real menos salario predicho: un valor positivo indica subestimación y uno negativo, sobreestimación. Los diagramas usan la misma muestra reproducible de 5,000 registros; las métricas por grupo se calcularon con el test completo.

Resultados globales (todo el test).

- **Random Forest:** error medio global +107.45 Q (subestima en promedio); subestima al 47.0% de los registros.
- **Regresión lineal:** error medio global +120.55 Q (subestima en promedio); subestima al 48.9% de los registros.

Lo que muestran las gráficas (muestra común de 5,000 registros).

- **Regresión lineal:** en la muestra, el residuo medio es Q105.62; para salarios reales desde el

percentil 90 es Q3,282.91. La dispersion crece con el nivel salarial, por lo que los errores no tienen varianza constante.

- **Random Forest:** en la muestra, el residuo medio es Q95.47; para salarios reales desde el percentil 90 es Q3,202.76. La dispersion crece con el nivel salarial, por lo que los errores no tienen varianza constante.




Figure 7: Salario real frente a predicho con referencia $y = x$.




Figure 8: Residuos frente a predicción con referencia horizontal en cero.

Nivel educativo	n	MAE RL	Err. medio RL	MAE RF	Err. medio RF
Ninguno	1,016	823.51	+109.34	708.92	-197.02
Preprimaria	80	735.21	+88.76	661.81	-192.45
Primaria	3,957	870.04	+54.56	777.34	-6.77
Basico	2,164	894.45	+127.77	850.43	+54.88
Diversificado	4,117	1,109.31	+103.98	1,045.38	+200.09
Superior	1,729	2,566.37	+295.51	2,358.83	+342.58
Maestria	183	5,552.88	-131.50	4,882.13	+39.54
Doctorado	12	12,919.31	+6,062.70	14,088.18	+10,397.51

Table 7: MAE y error medio (real – predicho) por nivel educativo; RL = regresión lineal, RF = Random Forest.

6.1 Errores por nivel educativo

- **Random Forest:** el mayor MAE por nivel educativo aparece en **Doctorado** (Q14,088.18, n=12). La mayor subestimación media ocurre en **Doctorado** (Q10,397.51) y la mayor sobreestimación ocurre en **Ninguno** (Q-197.02).
- **Regresión lineal:** el mayor MAE por nivel educativo aparece en **Doctorado** (Q12,919.31, n=12). La mayor subestimación media ocurre en **Doctorado** (Q6,062.70) y la mayor sobreestimación ocurre en **Maestria** (Q-131.50).

El grupo de nivel educativo con mayor salario promedio es **Doctorado** (Q20,291.67) y también concentra el mayor MAE absoluto; esto obliga a interpretar el MAE junto con la escala salarial y el número de observaciones.

6.2 Errores por dominio

Dominio	n	MAE RL	Err. medio RL	MAE RF	Err. medio RF
Resto Urbano	4,846	1,189.65	+134.28	1,085.55	+66.32
Rural Nacional	2,780	913.64	+65.24	813.65	-62.41
Urbano Metropolitano	5,632	1,446.09	+136.04	1,351.50	+226.68

Table 8: MAE y error medio (real – predicho) por dominio; RL = regresión lineal, RF = Random Forest.

- **Random Forest:** el mayor MAE por dominio aparece en **Urbano Metropolitano** (Q1,351.50, n=5,632). La mayor subestimación media ocurre en **Urbano Metropolitano** (Q226.68) y la mayor sobreestimación ocurre en **Rural Nacional** (Q-62.41).
- **Regresión lineal:** el mayor MAE por dominio aparece en **Urbano Metropolitano** (Q1,446.09, n=5,632). La mayor subestimación media ocurre en **Urbano Metropolitano** (Q136.04) y todos los grupos presentan subestimación media; la menor aparece en **Rural Nacional** (Q65.24).

El grupo de dominio con mayor salario promedio es **Urbano Metropolitano** (Q4,352.31) y también concentra el mayor MAE absoluto; esto obliga a interpretar el MAE junto con la escala salarial y el número de observaciones.

Banda	n	Salario prom.	MAE RL	Err. RL	MAE RF	Err. RF	RF subestima
P00-P25	4,032	1,298	998	-829	928	-868	10.9%
P25-P50	2,715	2,738	852	-161	701	-209	42.5%
P50-P75	3,188	3,769	831	-80	691	-26	60.5%
P75-P90	2,072	4,889	1,178	+486	1,200	+551	75.3%
P90-P95	608	7,225	2,076	+1,634	2,048	+1,644	88.3%
P95-P100	643	12,553	5,848	+5,645	5,524	+5,341	94.4%

Table 9: Error por banda del salario real de 2026T1 (todos los registros de prueba); error = real – predicho.

6.3 Errores según el percentil del salario real

- **Random Forest:** en P00-P25 el error medio es Q-868.49; en P95-P100 asciende a Q5,341.04, con MAE Q5,524.16 y 94.4% de registros subestimados.
- **Regresión lineal:** en P00-P25 el error medio es Q-828.73; en P95-P100 asciende a Q5,645.34, con MAE Q5,848.39 y 94.4% de registros subestimados.

Salarios bajos, medios y altos. **RF_50_arboles_d7** es el mejor modelo global por RMSE. Sin embargo, en P95-P100 todavía presenta un error medio de Q5,341.04 y un MAE de Q5,524.16; por tanto, una mejora promedio no elimina la dificultad de representar la cola salarial.

6.4 Respuestas a las preguntas de la actividad

- **Algoritmo con mejor generalización:** **RF_50_arboles_d7**, con RMSE Q2,050.55 y $R^2=0.4887$, frente a RMSE Q2,163.75 del otro algoritmo.
- **Nivel educativo con mayor error observado:** Doctorado para Random Forest (MAE Q14,088.18, n=12).
- **Dominio con mayor error observado:** Urbano Metropolitano para Regresión lineal (MAE Q1,446.09, n=5,632).
- **Banda mas difícil:** P95-P100 para Regresión lineal (MAE Q5,848.39). Los errores medios positivos en la cola alta indican subestimación sistemática de salarios altos.
- **Lectura correcta:** las diferencias son predictivas y descriptivas; no prueban causalidad ni determinan cuanto debería ganar una persona.

7 Conclusiones y limitaciones

El análisis identificó perfiles laborales diferenciados y demostro que **RF_50_arboles_d7** generaliza mejor a 2026T1: MAE Q1,141.51, RMSE Q2,050.55 y $R^2=0.4887$. Su RMSE es 28.59% menor que el de la referencia y también supera a **LR_sin_regularización**. La ventaja es compatible con la capacidad del bosque para representar no linealidades e interacciones entre educación, ocupación y territorio.

El desempeño no es uniforme. El mayor MAE por educación se observó en **Doctorado**, y por dominio en **Urbano Metropolitano**. En la banda P95-P100, el ganador conserva un MAE de Q5,524.16 y un error medio de Q5,341.04, evidencia de que la cola salarial sigue siendo difícil y tiende a subestimarse. El patrón debe interpretarse junto con el tamaño de cada grupo y la regresión a la media.




Figure 9: MAE y error medio por nivel educativo sobre todo el test.




Figure 10: MAE y error medio por dominio sobre todo el test.




Figure 11: Error según bandas del salario real de 2026T1.

Las metricas son no ponderadas y describen solamente asalariados elegibles con salario positivo registrado. No representan estimaciones oficiales de Guatemala ni efectos causales. La ausencia de variables como rama de actividad, ocupacion detallada o tamaño de empresa limita la varianza explicada; un uso posterior deberia estudiar estabilidad temporal, equidad por subgrupos y estimaciones ponderadas con FACTOR bajo el diseño muestral correspondiente.

Los resultados son no ponderados y describen solamente los registros elegibles analizados. No constituyen estimaciones oficiales de la población guatemalteca ni evidencian relaciones causales. FACTOR se conservó para documentar el diseño y permitir un análisis poblacional posterior.

8 Reproducibilidad y fuente

El notebook se ejecuta de principio a fin, fija semilla 42, mantiene 2026 fuera de la selección y limita pandas a agregados o a la muestra gráfica permitida. Los Excel, Parquet y modelos se mantienen fuera de Git por tamaño; el README documenta sus rutas y dependencias.

Instituto Nacional de Estadística de Guatemala. *Encuesta Nacional de Empleo e Ingresos Continua (ENEIC)*, bases de Personas 2025-2026.

<https://www.ine.gob.gt/encuesta-nacional-de-empleo-e-ingresos/>